

Clustering Jerárquico

Índice

1. Introducción	2
2. Funcionamiento	2
3. Tipos de enlace (linkage)	2
4. Ejemplo en Python	3
5. Interpretación del dendrograma	3
6. Comparación con K-Means	3
7. Ventajas e inconvenientes	4
8. Aplicaciones	4
9. Caso de uso real	4
9.1. Ejemplo: Segmentación de clientes	4
9.2. Ejemplo: Análisis de criminalidad	5
10. Conclusión	5

1. Introducción

El clustering jerárquico es una técnica de aprendizaje no supervisado que permite identificar agrupaciones en un conjunto de datos.

2. Funcionamiento

El clustering jerárquico organiza los datos en una estructura de tipo árbol denominada dendrograma. Existen dos enfoques principales:

- **Aglomerativo:** comienza con cada dato como un clúster independiente y los va fusionando.
- **Divisivo:** comienza con un único clúster y lo divide progresivamente.

Pasos del algoritmo aglomerativo:

1. Inicialización: cada punto es un clúster.
2. Cálculo de distancias entre clústeres.
3. Unión de los dos clústeres más cercanos.
4. Repetición del proceso hasta obtener un único clúster o el número deseado.

3. Tipos de enlace (linkage)

- **Single linkage:** distancia mínima entre elementos de dos clústeres.
- **Complete linkage:** distancia máxima entre elementos.
- **Average linkage:** distancia media entre elementos.

4. Ejemplo en Python

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.cluster.hierarchy import dendrogram, linkage
from sklearn.datasets import make_blobs

# Generar datos
X, _ = make_blobs(n_samples=100, centers=3, random_state
                 =42)

# Clustering jerárquico
Z = linkage(X, method="complete")

# Dendrograma
plt.figure(figsize=(10, 6))
dendrogram(Z)

plt.title("Dendrograma")
plt.xlabel("Índices de datos")
plt.ylabel("Distancia")
plt.show()
```

5. Interpretación del dendrograma

El dendrograma muestra cómo se agrupan los datos. La altura a la que se unen los clústeres indica la distancia entre ellos.

Para determinar el número de clústeres, se puede realizar un corte horizontal. Los grupos resultantes dependerán de la altura elegida.

6. Comparación con K-Means

- No requiere definir previamente el número de clústeres.
- Genera una estructura jerárquica.
- Tiene mayor coste computacional que K-Means.

7. Ventajas e inconvenientes

Ventajas:

- No necesita número de clústeres inicial.
- Permite visualizar la estructura de los datos.

Inconvenientes:

- Alto coste computacional.
- Sensible al ruido.

8. Aplicaciones

- Segmentación de clientes.
- Análisis de comportamiento delictivo.
- Agrupación de documentos.

9. Caso de uso real

El clustering jerárquico se utiliza en múltiples contextos reales donde es necesario identificar patrones o agrupaciones sin conocer previamente el número de grupos.

9.1. Ejemplo: Segmentación de clientes

Una empresa puede utilizar clustering jerárquico para agrupar a sus clientes en función de variables como:

- Edad
- Nivel de ingresos
- Frecuencia de compra
- Tipo de productos adquiridos

A diferencia de otros algoritmos como K-Means, el clustering jerárquico permite visualizar la relación entre los distintos grupos mediante un dendrograma, lo que facilita la interpretación de los resultados.

Por ejemplo, el análisis puede revelar que:

- Un grupo de clientes jóvenes con bajo gasto
- Un grupo de clientes con alto poder adquisitivo
- Un grupo intermedio con comportamiento mixto

Esta información permite a la empresa diseñar estrategias específicas para cada segmento, como campañas de marketing personalizadas o recomendaciones de productos.

9.2. Ejemplo: Análisis de criminalidad

En el ámbito del análisis de datos públicos, como los registros policiales, el clustering jerárquico puede utilizarse para identificar patrones en función de:

- Tipo de delito
- Ubicación geográfica
- Franja horaria

Esto permite detectar zonas con comportamientos similares o identificar agrupaciones de delitos que comparten características comunes.

El dendrograma ayuda a visualizar cómo se relacionan estos grupos y a determinar niveles de agrupación más o menos detallados, lo que resulta útil para la toma de decisiones en políticas de seguridad.

10. Conclusión

El clustering jerárquico es una herramienta potente para analizar la estructura de los datos sin necesidad de conocer previamente el número de grupos, aunque su coste computacional limita su uso en grandes volúmenes de datos.