

Aprendizaje No Supervisado

2025 - 2026

Índice

1. Introducción	3
2. Clustering	3
2.1. Ejemplo conceptual	3
3. Espacio de características	4
4. Medidas de distancia	4
5. Distancias más utilizadas	4
5.1. Distancia Euclídea	4
5.2. Distancia Manhattan	4
5.3. Distancia de Minkowski	5
6. Tipos de clustering	5
7. Algoritmo K-means	5
7.1. Funcionamiento	5
7.2. Centroide	5
7.3. Ventajas	6
7.4. Limitaciones	6
8. Método Elbow	6
9. DBSCAN	7
9.1. Tipos de puntos	7
9.2. Parámetros principales	7
9.3. Funcionamiento	7
9.4. Ventajas	8
9.5. Limitaciones	8
10. Clustering jerárquico	8
10.1. Tipos	8
10.2. Dendrograma	8

11. Parámetros e hiperparámetros	8
11.1. Parámetros	9
11.2. Hiperparámetros	9
12. Mapas Autoorganizados (SOM)	9
12.1. Ventajas	9
12.2. Limitaciones	9

1. Introducción

Definición

El **aprendizaje no supervisado** es una técnica de Machine Learning en la que los datos no tienen etiquetas. El objetivo del modelo es **descubrir patrones o estructuras ocultas** dentro de los datos.

A diferencia del aprendizaje supervisado, en el que se conoce la respuesta correcta para cada ejemplo, en el aprendizaje no supervisado el algoritmo debe analizar los datos y encontrar regularidades por sí mismo.

Idea clave

El objetivo principal del aprendizaje no supervisado es **descubrir estructura en los datos**.

Aplicaciones habituales:

- Segmentación de clientes
- Detección de anomalías
- Compresión de datos
- Análisis exploratorio de datos
- Reducción de dimensionalidad

2. Clustering

El **clustering** consiste en dividir un conjunto de datos en grupos denominados **clusters**.

Objetivo del clustering

- Maximizar la similitud entre elementos del mismo grupo
- Maximizar la diferencia entre grupos distintos

Cada cluster contiene observaciones que comparten características similares.

2.1. Ejemplo conceptual

Supongamos un dataset con clientes caracterizados por:

- edad
- ingresos

Un algoritmo de clustering podría identificar:

- clientes jóvenes con bajo gasto
- clientes adultos con alto gasto

3. Espacio de características

Cada variable del dataset representa una dimensión de un espacio.

- 2 variables $\rightarrow$ espacio bidimensional
- 3 variables $\rightarrow$ espacio tridimensional
- m variables $\rightarrow$ espacio m -dimensional

Cada observación puede representarse como un punto en ese espacio.

Idea clave

La distancia entre puntos representa el grado de similitud entre observaciones.

4. Medidas de distancia

Para agrupar observaciones se utilizan **medidas de distancia**.

Una función de distancia $d(x, y)$ debe cumplir:

- $d(x, y) \geq 0$
- $d(x, y) = 0$ si $x = y$
- $d(x, y) = d(y, x)$

5. Distancias más utilizadas

5.1. Distancia Euclídea

Es la distancia geométrica entre dos puntos.

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

5.2. Distancia Manhattan

También llamada **distancia de taxi**.

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

5.3. Distancia de Minkowski

Generaliza las anteriores.

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}$$

- $p = 1 \rightarrow$ Manhattan
- $p = 2 \rightarrow$ Euclídea

6. Tipos de clustering

Tipo	Característica	Ejemplo
Jerárquico	Construye una jerarquía de clusters	Dendrogramas
No jerárquico	Divide los datos en grupos independientes	K-means

7. Algoritmo K-means

K-means es uno de los algoritmos de clustering más utilizados.
Su objetivo es dividir los datos en K clusters.

7.1. Funcionamiento

1. Elegir K centroides iniciales.
2. Asignar cada punto al centroide más cercano.
3. Recalcular los centroides.
4. Repetir hasta convergencia.

7.2. Centroide

El centroide de un cluster es el promedio de las observaciones del grupo.

$$\mu_k = \frac{1}{n_k} \sum_{i \in C_k} x_i$$

Idea clave

K-means intenta minimizar la varianza dentro de cada cluster.

7.3. Ventajas

- Fácil de implementar
- Escalable a grandes datasets
- Computacionalmente eficiente

7.4. Limitaciones


- Hay que elegir el número de clusters K
- Sensible a valores atípicos
- Puede depender de la inicialización

8. Método Elbow

Conocido también como Método del Codo, su finalidad es encontrar el mejor valor de K (número óptimo de clústers). La idea detrás de este método es bastante sencilla. Identificar el número de clústeres para el que se observa un cambio significativo en la tasa de disminución de la varianza intra-cluster (también conocido como suma total de las distancias al cuadrado).

Para ello se debe ejecutar el algoritmo de k-means con diferentes números de clústeres (k) y calcular la suma de las distancias al cuadrado de cada punto respecto a su centroide. Usando los resultados para crear una gráfica con los valores de k en el eje x y la suma de las distancias al cuadrado en el eje y.

En esta gráfica se busca el punto donde se produce un cambio brusco en la disminución de la suma de las distancias al cuadrado. Punto en el que la curva muestra la forma de un codo.



El número óptimo de clústeres se corresponde con este punto que se conoce como el “codo”.

Podemos comprobar el algoritmo en el siguiente enlace:
Algoritmo del Método Elbow

9. DBSCAN

Definición

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo de clustering basado en densidad que agrupa observaciones que se encuentran en regiones densas del espacio de características.

A diferencia de K-means, DBSCAN no utiliza centroides ni requiere fijar previamente el número de clusters.

Idea clave

DBSCAN identifica clusters como regiones donde la densidad de puntos es alta, separadas por regiones donde la densidad es baja.

9.1. Tipos de puntos

DBSCAN clasifica las observaciones en tres tipos:

- **Core points:** puntos que tienen muchos vecinos cercanos.
- **Border points:** puntos cercanos a un cluster pero con menos vecinos.
- **Noise:** puntos aislados que no pertenecen a ningún cluster.

9.2. Parámetros principales

El algoritmo utiliza dos hiperparámetros:

- ε (epsilon): radio máximo de vecindad.
- *minPts*: número mínimo de puntos dentro del radio ε .

9.3. Funcionamiento

1. Se selecciona un punto del dataset.
2. Se buscan todos los puntos dentro del radio ε .
3. Si hay al menos *minPts* puntos, se forma un cluster.
4. El proceso continúa expandiendo el cluster.
5. Los puntos que no pertenecen a ningún cluster se consideran ruido.

9.4. Ventajas

- No requiere elegir el número de clusters.
- Puede detectar clusters con formas irregulares.
- Permite identificar outliers de forma natural.

9.5. Limitaciones

- Sensible a la elección de ε .
- Puede tener dificultades con datasets con densidades muy distintas.

10. Clustering jerárquico

El clustering jerárquico crea una estructura en forma de árbol de clusters.

10.1. Tipos

Aglomerativo

- Cada observación comienza como un cluster.
- Los clusters se van fusionando.

Divisivo

- Todos los datos comienzan en un cluster.
- El cluster se divide progresivamente.

10.2. Dendrograma

El resultado suele representarse mediante un **dendrograma**.
Este gráfico muestra:

- cómo se agrupan los clusters
- la distancia a la que se fusionan

11. Parámetros e hiperparámetros

En los modelos de Machine Learning distinguimos:

11.1. Parámetros

Valores aprendidos automáticamente durante el entrenamiento.
Ejemplo: coeficientes de un modelo.

11.2. Hiperparámetros

Valores definidos antes del entrenamiento.
Ejemplos:

- número de clusters K
- número de vecinos en KNN
- tasa de aprendizaje

12. Mapas Autoorganizados (SOM)

Los **Self Organizing Maps (SOM)** son redes neuronales utilizadas para clustering y visualización de datos.

Organizan los datos en una **rejilla bidimensional** donde neuronas cercanas representan observaciones similares.

12.1. Ventajas

- Permiten visualizar datos complejos
- Conservan relaciones de vecindad
- Útiles en análisis exploratorio

12.2. Limitaciones

- Sensibles a la inicialización
- Requieren ajustar hiperparámetros
- Pueden converger a soluciones subóptimas